

Aprendizaje Automático

Tarea Semana 8

Objetivo:

Identificar cuántos segmentos latentes de clientes existen a partir de sus comportamientos de compra y uso del sitio, sin etiquetas previas.

Qué patrones buscar:

- Grupos con frecuencia alta pero ticket bajo y alta sensibilidad a descuentos.
- Grupos con frecuencia baja pero ticket alto y baja sensibilidad (compras esporádicas pero grandes).
- Grupos con tiempo en sitio y tasa de devoluciones diferenciados (p. ej., exploran mucho y devuelven más vs. exploran poco y devuelven menos).


Cómo validarlo:

- Comparar $k=2..6$ usando método del codo para justificar qué valor de k es razonable.
- Analizar los centroides por cluster para describir perfiles (p. ej., “Cluster 1: alta frecuencia + ticket medio + sensibilidad media, foco para promociones; Cluster 2: ticket alto + baja sensibilidad, foco en upselling premium”, etc.)

Desarrollo


Selección de K

Vamos a comenzar analizando cuál es el valor razonable de K . A partir del Método del Codo y la Evaluación mediante Silhouette se intenta identificar la cantidad de segmentos latentes a partir de sus comportamientos de compra y uso del sitio.




Por lo que vemos en los gráficos de uno y otro método la cantidad de segmentos podrían estar entre 3 y 4. En el Método del Codo se utiliza el k que marca el codo, en este caso, $k=3$. En Evaluación mediante Silhouette se identifican los puntos más altos locales, en este caso $k=3$ sería la primera opción, pero $k=4$ proporcionó sólo un poco menor. En general se utilizaría el menor de los dos, $k=3$. En el Notebook se realizó el análisis con $k=4$, sin mejorar los resultado o segmentos

Otra herramienta que puede reforzar la elección de $k=3$ son las silhouette plots. Con $k=3$ vemos un promedio de silhouette levemente mejor, franjas bien distribuidas. Con $k=4$, aparece un cluster más débil(verde) que puede parecer una fragmentación del verde original. Por lo que veremos luego, no aporta mucho al análisis.



Análisis de Segmentos

A continuación, vamos a analizar los centroides para describir los segmentos identificados. Por lo que analizamos en los párrafos anteriores, los datos sugieren la existencia de 3 segmentos. Para caracterizarlos visualmente vamos a analizar un gráfico dónde se identifican los 3 centroides, que representan los 3 segmentos identificados. Los valores están normalizados para poder comparar sus valores con una misma escala, y se superpone además los boxplot de cada uno de los para tener una referencia adicional de los valores.



La caracterización de los valores se propone de la siguiente manera:

alta	$z \geq 0,5$
media	$0,5 \geq z \geq -0,5$
baja	$z \leq -0,5$

El primer segmento, representado por Cluster 0, se puede caracterizar por frecuencia alta, ticket medio y estadía alta.

El segundo segmento, representado por Cluster 1, se puede caracterizar por frecuencia baja, ticket alto y estadía baja.

El tercer segmento, representado por Cluster 2, se puede caracterizar por frecuencia media, ticket bajo, y estadía media.

En los tres segmentos la sensibilidad y devoluciones se mantienen dentro de la media.

Esto no coincide con ninguno de los tres patrones propuestos por la consigna.

Patron 1, frecuencia alta, ticket bajo, y sensibilidad alta.


Patron 2, frecuencia baja, ticket alto, y sensibilidad baja.

Patron 3, estadía alta y devoluciones altas.

Patron 4, estadía baja y devoluciones bajas.

Análisis con K=4

Sólo para validar si se podía llegar a mejorar la segmentación, y considerando que el silhouette score para k=4 era sólo un poco menor que para k=3, buscando que coincidiera con los patrones sugeridos inicialmente, se realizó el análisis para k=4. A continuación les proporciono el mismo gráfico anterior pero con 4 segmentos.



El primer segmento, representado por Cluster 0, se puede caracterizar por frecuencia alta, ticket medio y estadía alta. Las devoluciones se mantienen medias.

El segundo segmento, representado por Cluster 1, se puede caracterizar por frecuencia baja, ticket alto y estadía baja. Las devoluciones son altas.

El tercer segmento, representado por Cluster 2, se puede caracterizar por frecuencia media, ticket bajo, y estadía media. Las devoluciones se mantienen medias.

El cuarto segmento, representado por Cluster 3, se puede caracterizar por frecuencia baja, ticket alto y estadía baja. Las devoluciones son bajas.

En los segmentos la sensibilidad se mantiene media.

Si bien aparece una diferenciación entre las devoluciones para los segmentos dos y cuatro, la sensibilidad se mantiene dentro del segmento medio, de manera que no se puede distinguir ningún segmento con permanencia y devoluciones diferenciadas. Eventualmente podría ser con devoluciones diferenciadas. En definitiva, el segmento adicional, con k=4, no aporta mayor información que la segmentación en tres partes, k=3. Al menos no el sentido que podría llegar a ser de utilidad.